



Fundamentos y Algoritmia para Inteligencia Artificial

**MATERIAL TÉCNICO
DE APOYO**

TAREA N°01

Estudia los fundamentos de Inteligencia Artificial.

Fundamentos de inteligencia artificial: Conceptos y aplicaciones.

➤ Diferencias entre IA, Machine Learning y Deep Learning.

- Inteligencia Artificial (IA)
 - Definición:
La Inteligencia Artificial (IA) es un campo de la informática que se centra en la creación de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana. Estas tareas incluyen el reconocimiento de voz, la toma de decisiones, la traducción de idiomas, la percepción visual, etc.
 - Ámbito:
La IA es un término amplio que engloba varias subdisciplinas, incluyendo Machine Learning (ML) y Deep Learning (DL). Puede abarcar desde sistemas de lógica difusa hasta sistemas expertos y razonamiento basado en reglas.

Ejemplos:

- Chatbots
- Sistemas de recomendación
- Reconocimiento de voz
- Sistemas de diagnóstico médico

Machine Learning (ML)

- Definición:
Machine Learning es una subdisciplina de la IA que se centra en el desarrollo de algoritmos que permiten a las computadoras aprender de y hacer predicciones o decisiones basadas en datos. En lugar de ser explícitamente programados para realizar una tarea, los sistemas de ML son entrenados en grandes conjuntos de datos para reconocer patrones y hacer inferencias.
- Tipos de Aprendizaje:
Aprendizaje Supervisado: El modelo es entrenado con datos etiquetados. Cada entrada viene con una salida correspondiente, y el objetivo es aprender una función que mapeará correctamente las entradas a las salidas.

Ejemplos: Clasificación (p.ej., detección de spam), regresión (p.ej., predicción de precios).

Aprendizaje No Supervisado: El modelo es entrenado con datos no etiquetados y debe encontrar estructuras y patrones ocultos en los datos.

Ejemplos: Clustering (p.ej., segmentación de clientes), asociación (p.ej., detección de reglas de mercado).

Aprendizaje por Refuerzo: El modelo aprende mediante prueba y error, recibiendo recompensas o penalizaciones según sus acciones.

Ejemplos: Juegos (p.ej., AlphaGo), control de robots.

- Ejemplos:
 - Clasificación de correos electrónicos como spam o no spam
 - Recomendaciones de productos
 - Detección de fraudes
- Deep Learning (DL)
- Definición:

Deep Learning es una subdisciplina de Machine Learning que utiliza redes neuronales artificiales con muchas capas (profundas) para modelar y entender patrones complejos en grandes cantidades de datos. Las redes neuronales profundas pueden aprender representaciones de datos en múltiples niveles de abstracción.
- Arquitecturas Comunes:

Redes Neuronales Convolucionales (CNNs): Utilizadas principalmente para procesamiento de imágenes y visión por computadora.
Ejemplos: Reconocimiento facial, clasificación de imágenes.

Redes Neuronales Recurrentes (RNNs): Utilizadas para datos secuenciales, como series temporales y procesamiento de lenguaje natural.
Ejemplos: Traducción automática, generación de texto.
- Autoencoders y Generative Adversarial Networks (GANs): Utilizados para reducción de dimensionalidad, generación de datos y aprendizaje no supervisado.
Ejemplos: Creación de imágenes sintéticas, detección de anomalías.

Ejemplos:

- Reconocimiento de voz
- Análisis de sentimientos
- Vehículos autónomos
- Diagnóstico médico mediante imágenes

- Resumen de Diferencias

- ❖ IA:

- Ámbito amplio que incluye cualquier sistema que realice tareas que requieran inteligencia humana.
- Incluye Machine Learning y otras técnicas como lógica difusa y sistemas basados en reglas.

- ❖ Machine Learning:

- Subcampo de la IA.
- Se centra en algoritmos que permiten a las computadoras aprender de los datos.
- Tipos principales: aprendizaje supervisado, no supervisado y por refuerzo.

- ❖ Deep Learning:

- Subcampo de Machine Learning.
- Utiliza redes neuronales profundas para modelar patrones complejos.
- Es especialmente eficaz con grandes volúmenes de datos y tareas de alta complejidad como el reconocimiento de imágenes y el procesamiento del lenguaje natural.

La Inteligencia Artificial es el campo más amplio que abarca todas las técnicas que permiten a las máquinas imitar el comportamiento humano. Machine Learning es una subdisciplina de la IA que implica el uso de algoritmos para aprender de datos y hacer predicciones. Deep Learning es una subdisciplina de Machine Learning que utiliza redes neuronales profundas para analizar datos y aprender de ellos de manera más detallada y compleja.

Cada uno de estos campos tiene su propio conjunto de técnicas y aplicaciones, y a menudo se superponen y se utilizan juntos para resolver problemas complejos.

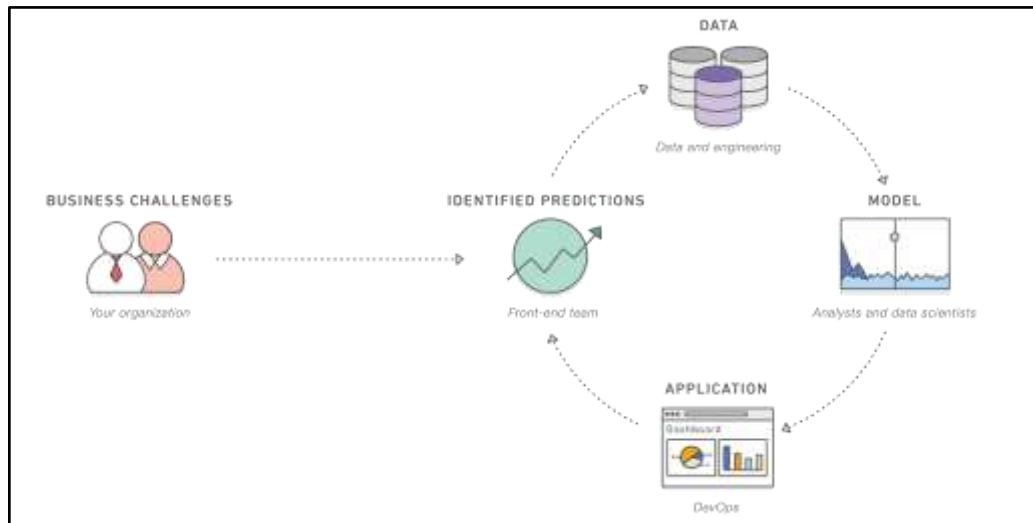


Figura N° 01: IA en la automatización de procesos industriales.

➤ **Definición de aprendizaje automático.**

- El aprendizaje automático (o *Machine Learning* en inglés) es una subdisciplina de la inteligencia artificial que se enfoca en el desarrollo de algoritmos y modelos que permiten a las computadoras aprender a realizar tareas específicas a partir de datos, sin ser programadas explícitamente para cada tarea en particular. Es decir, en lugar de seguir instrucciones predefinidas, los sistemas de aprendizaje automático utilizan patrones y datos para mejorar su desempeño en tareas específicas a medida que reciben más datos.

- **Definición detallada**

Aprendizaje Automático: Es un campo de estudio de la inteligencia artificial que se centra en el diseño y desarrollo de algoritmos que permiten a los sistemas computacionales mejorar automáticamente a través de la experiencia. Estos algoritmos construyen un modelo matemático basado en datos de entrenamiento, que es utilizado para hacer predicciones o tomar decisiones sin ser programados específicamente para cada tarea.

- **Características principales**

- **Automatización:** Permite a los sistemas aprender y mejorar automáticamente sin intervención humana constante.
- **Adaptabilidad:** Los modelos de aprendizaje automático pueden adaptarse y actualizarse con nuevos datos.
- **Predicción:** Se utiliza para hacer predicciones basadas en patrones encontrados en datos históricos.
- **Generalización:** Un buen modelo de aprendizaje automático generaliza bien de los datos de entrenamiento a datos nuevos y no vistos.

- Tipos de Aprendizaje Automático
 - Aprendizaje Supervisado:
 - El modelo es entrenado con datos etiquetados, donde cada entrada está asociada a una salida.
 - Objetivo: Aprender una función que mapea entradas a salidas.
 - Ejemplos: Clasificación (e.g., detección de spam), regresión (e.g., predicción de precios).
 - Aprendizaje No Supervisado:
 - El modelo es entrenado con datos no etiquetados, sin salidas asociadas.
 - Objetivo: Encontrar patrones o estructuras ocultas en los datos.
 - Ejemplos: Clustering (e.g., segmentación de clientes), asociación (e.g., análisis de cesta de mercado).
 - Aprendizaje por Refuerzo:
 - El modelo aprende a través de interacciones con el entorno, recibiendo recompensas o penalizaciones.
 - Objetivo: Aprender una política para maximizar las recompensas a largo plazo.
 - Ejemplos: Juegos (e.g., AlphaGo), control de robots.
- Ejemplos de Aplicaciones
 - Reconocimiento de imágenes: Clasificación de imágenes en categorías predefinidas.
 - Procesamiento del lenguaje natural (NLP): Análisis de sentimientos, traducción automática.
 - Sistemas de recomendación: Recomendación de productos o contenido basado en el comportamiento del usuario.
 - Detección de fraudes: Identificación de transacciones fraudulentas en tiempo real.
 - Diagnóstico médico: Predicción de enfermedades basadas en datos de pacientes.
- Algoritmos Comunes
 - Regresión Lineal y Logística: Modelos simples para predicciones continuas y clasificación binaria.
 - Árboles de Decisión: Modelos basados en la división iterativa de datos en subconjuntos más pequeños.
 - Máquinas de Vectores de Soporte (SVM): Modelos que buscan hiperplanos que separan datos de diferentes clases.

- Redes Neuronales: Modelos inspirados en la estructura del cerebro humano, utilizados especialmente en aprendizaje profundo.
- K-Means: Algoritmo de clustering que agrupa datos en k clusters basados en la proximidad.

El aprendizaje automático es una herramienta poderosa que permite a las computadoras aprender de los datos y mejorar su desempeño en tareas específicas sin programación explícita para cada tarea. Se utiliza ampliamente en diversas industrias para tareas como predicción, clasificación, detección de patrones y toma de decisiones automatizadas.

➤ Tipos de aprendizaje automático.

El aprendizaje automático se divide en varios tipos, cada uno con sus características y aplicaciones específicas. Los tres tipos principales son el aprendizaje supervisado, el aprendizaje no supervisado y el aprendizaje por refuerzo. Además, existen otros tipos y subtipos que se derivan de estos principales.

- Aprendizaje Supervisado.
 - Definición:
El aprendizaje supervisado utiliza un conjunto de datos etiquetados para entrenar a los algoritmos. En este contexto, "etiquetado" significa que cada entrada del conjunto de datos viene con una salida esperada. El objetivo del algoritmo es aprender una función que mapee entradas a salidas correctas.
 - Aplicaciones:
Clasificación: Asignar categorías a las entradas (e.g., detección de spam en correos electrónicos, reconocimiento de dígitos escritos a mano).
Regresión: Predecir valores continuos (e.g., predicción de precios de viviendas, estimación de ventas futuras).
 - Ejemplos de algoritmos:
 - Regresión lineal y logística
 - Máquinas de vectores de soporte (SVM)
 - Árboles de decisión y bosques aleatorios
 - Redes neuronales
- Aprendizaje No Supervisado.
 - Definición:
El aprendizaje no supervisado trabaja con datos que no están etiquetados. El objetivo es encontrar estructuras, patrones o agrupaciones ocultas dentro de los datos. Los algoritmos no supervisados intentan inferir las propiedades intrínsecas de los datos sin referencia a valores de salida conocidos.

- Aplicaciones:
 - Clustering: Agrupación de datos en subconjuntos (e.g., segmentación de clientes en marketing, agrupación de artículos similares).
 - Asociación: Descubrir reglas de asociación entre variables en grandes bases de datos (e.g., análisis de cesta de mercado, detección de patrones de compra).
- Ejemplos de algoritmos:
 - K-means
 - Algoritmo de agrupamiento jerárquico
 - Mapas autoorganizados (SOM)
 - Apriori y Eclat (para reglas de asociación)
- Aprendizaje por Refuerzo
 - Definición:

El aprendizaje por refuerzo se centra en cómo los agentes deben tomar acciones en un entorno para maximizar una recompensa acumulada a lo largo del tiempo. Los algoritmos de aprendizaje por refuerzo aprenden mediante prueba y error, recibiendo recompensas o penalizaciones basadas en las acciones que toman.
 - Aplicaciones:
 - Juegos (e.g., AlphaGo de Google)
 - Control de robots
 - Sistemas de recomendación en tiempo real
 - Trading algorítmico
 - Ejemplos de algoritmos:
 - Q-learning
 - SARSA (State-Action-Reward-State-Action)
 - Deep Q-Networks (DQN)
 - Algoritmos de política como el Actor-Critic
- Otros Tipos y Subtipos
 - Aprendizaje Semisupervisado:

Combina una pequeña cantidad de datos etiquetados con una gran cantidad de datos no etiquetados durante el entrenamiento. Esto es útil cuando obtener datos etiquetados es costoso o laborioso.

- **Aprendizaje Autónomo:**
También conocido como aprendizaje de autoentrenamiento, donde el modelo se entrena iterativamente usando sus propias predicciones como etiquetas para datos no etiquetados.
- **Aprendizaje de Transferencia:**
Utiliza el conocimiento adquirido mientras se resuelve un problema y lo aplica a un problema diferente pero relacionado. Es comúnmente utilizado en aplicaciones de visión por computadora y procesamiento del lenguaje natural.
- **Aprendizaje Profundo (Deep Learning):**
Un subcampo del aprendizaje automático que utiliza redes neuronales profundas para modelar y entender patrones complejos en grandes volúmenes de datos. Se puede aplicar tanto a tareas supervisadas como no supervisadas.
- **Ejemplos de algoritmos:**
 - Redes neuronales convolucionales (CNNs) para visión por computadora.
 - Redes neuronales recurrentes (RNNs) para datos secuenciales.
 - Autoencoders para reducción de dimensionalidad.
 - Redes generativas adversariales (GANs) para generación de datos sintéticos.

El aprendizaje automático se divide en varios tipos principales, cada uno adecuado para diferentes tipos de tareas y problemas. El aprendizaje supervisado se utiliza para tareas donde se dispone de datos etiquetados, el aprendizaje no supervisado se aplica cuando los datos no están etiquetados, y el aprendizaje por refuerzo es ideal para entornos dinámicos donde las decisiones se toman en secuencia y se evalúan por sus consecuencias. Además, existen subtipos y enfoques híbridos que permiten una mayor flexibilidad y eficiencia en el desarrollo de modelos de aprendizaje automático.




Figura N° 02: Principales tecnológicas de la IA.

➤ **Aprendizaje supervisado.**

El aprendizaje supervisado es una técnica de machine learning en la cual un algoritmo aprende a partir de un conjunto de datos etiquetados. Este tipo de aprendizaje se utiliza para crear modelos predictivos que mapean entradas (features) a salidas (labels) específicas. La idea principal es entrenar al modelo utilizando datos históricos con resultados conocidos para que pueda hacer predicciones o clasificaciones precisas sobre nuevos datos.

Conceptos Clave del Aprendizaje Supervisado.

- **Datos de Entrenamiento:**
 - **Características (Features):** Las variables de entrada que se utilizan para hacer predicciones.
 - **Etiquetas (Labels):** Las salidas correspondientes o respuestas correctas que el modelo debe predecir.
- **Modelo:**
 - Una función matemática que mapea entradas a salidas basado en los datos de entrenamiento.
 - El objetivo del entrenamiento es ajustar los parámetros del modelo para minimizar la diferencia entre las predicciones del modelo y las etiquetas reales.

- Función de Pérdida (Loss Function):
 - Una medida de cuán bien el modelo predice las etiquetas correctas. El objetivo del entrenamiento es minimizar esta función.
- Optimización:
 - Algoritmos como el descenso de gradiente se utilizan para ajustar los parámetros del modelo y minimizar la función de pérdida.

Tipos de Aprendizaje Supervisado.

- Clasificación:
 - El objetivo es predecir una categoría o clase discreta.
 - Ejemplos:
 - Clasificación Binaria: Detección de spam (spam o no spam).
 - Clasificación Multiclase: Clasificación de tipos de flores (setosa, versicolor, virginica).
- Regresión:
 - El objetivo es predecir un valor continuo.
 - Ejemplos:
 - Regresión Lineal: Predicción de precios de viviendas.
 - Regresión Polinómica: Predicción de curvas de crecimiento.

Ejemplos de Algoritmos de Aprendizaje Supervisado.

- Regresión Lineal:
Un modelo simple que asume una relación lineal entre las características de entrada y la salida.
Fórmula: $y = mx + b$
- Regresión Logística:
Utilizada para problemas de clasificación binaria.
Fórmula: $P(y = 1) = \frac{1}{1 + e^{-(b + \sum(w_i x_i))}}$
- Árboles de Decisión:
Modelo basado en un árbol donde los nodos representan características y las ramas representan decisiones que llevan a una clasificación o predicción.
- Máquinas de Vectores de Soporte (SVM):
Encuentra el hiperplano que mejor separa las clases en el espacio de características.

- **K-Vecinos Más Cercanos (K-NN):**
Clasifica una nueva instancia basada en las clases de sus k vecinos más cercanos en el espacio de características.
- **Redes Neuronales:**
Modelos que simulan la estructura del cerebro humano con capas de neuronas interconectadas.
Utilizadas tanto para clasificación como para regresión.

Proceso de Aprendizaje Supervisado

- **Recopilación de Datos:**
Recopilar un conjunto de datos grande y representativo con características y etiquetas.
- **Preprocesamiento de Datos:**
Limpieza y transformación de datos.
Normalización o estandarización de características.
Manejo de valores perdidos.
- **División del Conjunto de Datos:**
Dividir los datos en conjuntos de entrenamiento y prueba (y a veces un conjunto de validación).
- **Entrenamiento del Modelo:**
Ajustar los parámetros del modelo usando el conjunto de entrenamiento.
- **Evaluación del Modelo:**
Medir el rendimiento del modelo utilizando el conjunto de prueba.
Métricas comunes: precisión, recall, F1-score, error cuadrático medio (MSE), etc.
- **Ajuste de Hiperparámetros:**
Optimizar los parámetros del modelo para mejorar su rendimiento.
- **Implementación y Monitoreo:**
Desplegar el modelo en un entorno de producción y monitorear su desempeño en tiempo real.

Ventajas y Desventajas

Ventajas:

- Modelos supervisados suelen ser precisos y eficientes cuando se dispone de suficientes datos etiquetados.

- Son fáciles de interpretar y entender, especialmente los modelos simples como la regresión lineal y los árboles de decisión.

Desventajas:

- Requieren una gran cantidad de datos etiquetados, lo cual puede ser costoso y llevar mucho tiempo.
- Pueden sufrir de sobreajuste (overfitting) si el modelo es demasiado complejo para la cantidad de datos disponibles.

El aprendizaje supervisado es una herramienta fundamental en machine learning que permite a los sistemas aprender de datos etiquetados para hacer predicciones o clasificaciones precisas. Con una variedad de algoritmos y técnicas disponibles, se puede aplicar a una amplia gama de problemas en diferentes dominios. Sin embargo, la disponibilidad de datos de alta calidad y un buen entendimiento de los métodos de evaluación y optimización son cruciales para el éxito en el aprendizaje supervisado.

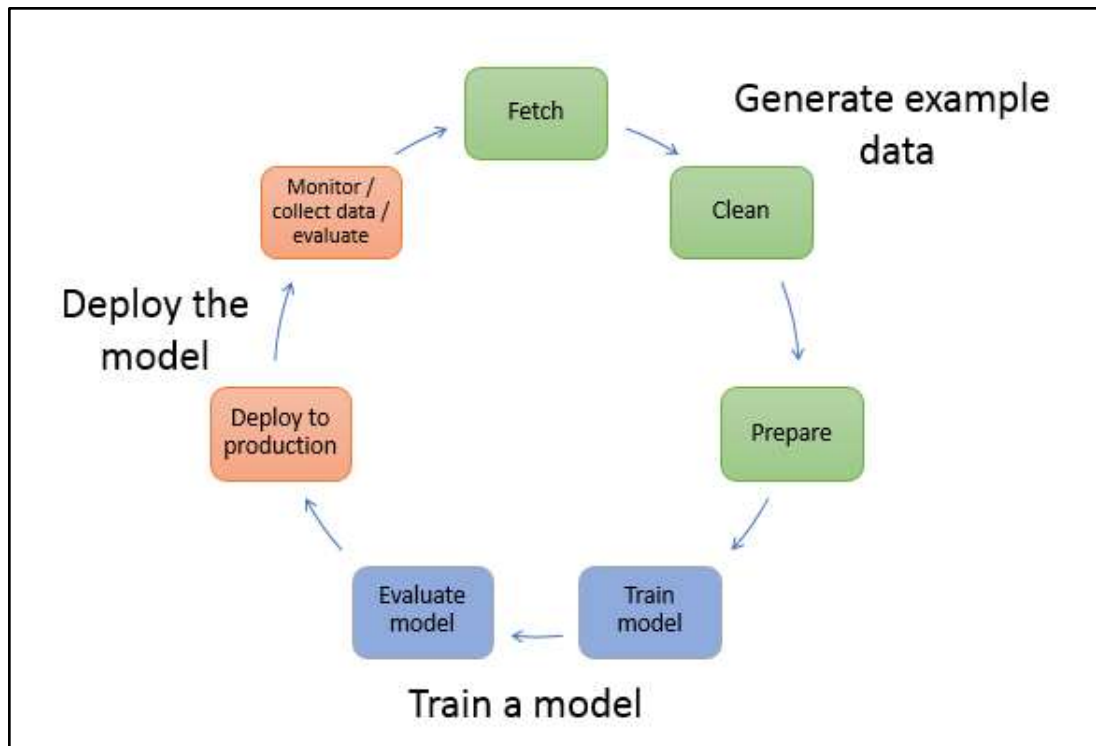


Figura N° 03: Diferencias entre el ML supervisado y el no supervisado.

➤ **Aprendizaje no supervisado.**

El aprendizaje no supervisado es un tipo de machine learning en el que los algoritmos se utilizan para analizar y agrupar datos no etiquetados. A diferencia del aprendizaje supervisado, donde los datos de entrada vienen con etiquetas, en el aprendizaje no supervisado no se proporcionan etiquetas. El objetivo principal es encontrar patrones y estructuras ocultas en los datos.

Características Clave del Aprendizaje No Supervisado.

- Datos No Etiquetados:
 - Los algoritmos trabajan con datos que no tienen salidas predefinidas (etiquetas).
 - El objetivo es identificar relaciones, patrones o estructuras dentro de los datos.
- Objetivo:
 - Descubrir la estructura subyacente de los datos sin ninguna guía.
 - Encontrar agrupaciones o asociaciones en los datos.

Principales Técnicas de Aprendizaje No Supervisado.

- Clustering (Agrupamiento):
 - Agrupa datos en subconjuntos o clústeres, donde los datos dentro de cada clúster son más similares entre sí que con los datos de otros clústeres.
 - Ejemplos:
 - K-means: Divide los datos en k clústeres mediante la minimización de la variación dentro de cada clúster.
 - Clustering Jerárquico: Crea una jerarquía de clústeres anidados mediante la combinación o división recursiva de clústeres.
 - DBSCAN (Density-Based Spatial Clustering of Applications with Noise): Identifica clústeres basados en la densidad de puntos, manejando bien los ruidos y los clústeres de formas arbitrarias.
- Asociación:
 - Encuentra reglas que describen grandes porciones de los datos, identificando relaciones interesantes entre variables.
 - Ejemplo:
 - Algoritmo Apriori: Identifica reglas de asociación en bases de datos transaccionales (e.g., "si compra leche, es probable que también compre pan").
 - Algoritmo Eclat: Una variante del algoritmo Apriori que utiliza intersección de conjuntos para encontrar itemsets frecuentes.
- Reducción de Dimensionalidad:
 - Reduce el número de variables bajo consideración, extrayendo las características más importantes de los datos.
 - Ejemplos:
 - Análisis de Componentes Principales (PCA): Transforma las variables originales en un conjunto de variables no correlacionadas llamadas componentes principales.

- t-SNE (t-Distributed Stochastic Neighbor Embedding): Una técnica de reducción de dimensionalidad que se usa para la visualización de datos en espacios de alta dimensión.
- Modelado de Distribuciones:
 - Ajusta un modelo probabilístico a los datos para hacer suposiciones sobre su estructura.
 - Ejemplo:
 - Modelos de Mezcla Gaussiana (GMM): Asumen que los datos son una mezcla de varias distribuciones gaussianas y estiman los parámetros de estas distribuciones.

Aplicaciones del Aprendizaje No Supervisado

- Segmentación de Clientes: Dividir a los clientes en grupos distintos basados en su comportamiento o características demográficas para campañas de marketing personalizadas.
- Análisis de Cesta de Mercado: Identificar productos que se compran juntos con frecuencia para optimizar la disposición en tiendas o promociones.
- Detección de Anomalías: Identificar patrones que no encajan con el comportamiento normal de los datos, útil en detección de fraudes o fallos en sistemas.
- Reducción de Ruido en Datos: Limpiar y preprocesar datos para mejorar la calidad del análisis posterior.
- Recomendadores de Contenidos: Sugerir productos, películas, libros, etc., basados en patrones de consumo similares entre usuarios.

Ejemplos de Algoritmos de Aprendizaje No Supervisado

- K-means Clustering:
Iterativamente asigna cada punto de datos al clúster más cercano y luego recalcula los centroides de los clústeres.
- Clustering Jerárquico:
Construye una jerarquía de clústeres mediante la combinación o división recursiva de clústeres.
- DBSCAN:
Identifica clústeres en función de la densidad de puntos y maneja bien los ruidos y los clústeres de formas arbitrarias.
- Apriori:
Encuentra patrones de asociación en bases de datos transaccionales.

- PCA (Análisis de Componentes Principales):
Reduce la dimensionalidad de los datos transformándolos en un conjunto de componentes principales no correlacionadas.
- t-SNE:
Una técnica de reducción de dimensionalidad que visualiza datos de alta dimensión en dos o tres dimensiones.

Desafíos del Aprendizaje No Supervisado.

- Interpretabilidad: Los resultados pueden ser difíciles de interpretar sin etiquetas.
- Validación: Es más difícil validar y evaluar el rendimiento de los modelos no supervisados ya que no hay una "verdad" conocida.
- Determinación del Número de Clústeres: En técnicas como K-means, determinar el número adecuado de clústeres puede ser desafiante.
- Dependencia de Escalado de Datos: Algunas técnicas, como el clustering, pueden ser sensibles a la escala de los datos, requiriendo normalización o estandarización.

El aprendizaje no supervisado es una herramienta poderosa para descubrir patrones ocultos y estructuras en datos no etiquetados. Se aplica en diversas áreas como segmentación de clientes, análisis de cesta de mercado, detección de anomalías y más. A pesar de sus desafíos, las técnicas no supervisadas ofrecen un enfoque flexible y exploratorio para el análisis de datos, proporcionando valiosas ideas y descubrimientos cuando las etiquetas no están disponibles.

➤ **Aprendizaje por reforzamiento.**

El aprendizaje por reforzamiento es una rama del machine learning donde un agente aprende a tomar decisiones mediante la interacción con su entorno para maximizar una recompensa acumulada. A diferencia del aprendizaje supervisado, donde el modelo se entrena con datos etiquetados, y del aprendizaje no supervisado, donde se descubren patrones en datos no etiquetados, el aprendizaje por reforzamiento se centra en el aprendizaje basado en la experiencia y la retroalimentación continua.

Conceptos Clave del Aprendizaje por Reforzamiento.

- Agente:
El sistema que toma acciones para interactuar con el entorno.
- Entorno:
El mundo con el que el agente interactúa y que responde a las acciones del agente.

- Estado:
La representación del entorno en un momento específico. Es la información que el agente percibe para decidir la próxima acción.
- Acción:
Las decisiones o movimientos que el agente puede realizar en el entorno.
- Recompensa:
La retroalimentación que el agente recibe del entorno como resultado de una acción. Puede ser positiva (recompensa) o negativa (castigo).
- Política (Policy):
La estrategia que el agente sigue para tomar decisiones. Puede ser determinística (siempre la misma acción en el mismo estado) o estocástica (acciones basadas en probabilidades).
- Valor (Value):
Una estimación de la futura recompensa acumulada que se puede obtener desde un estado o realizando una acción en un estado. Se utilizan dos funciones de valor:
 - o Función de valor de estado ($V(s)$): Valor esperado de la recompensa acumulada comenzando desde el estado s .
 - o Función de valor de acción ($Q(s, a)$): Valor esperado de la recompensa acumulada tomando la acción a en el estado s .

Proceso de Aprendizaje por Reforzamiento.

- Inicialización:
Definir el entorno, el agente y las posibles acciones.
- Interacción:
El agente observa el estado actual del entorno, selecciona una acción basada en su política, y recibe una recompensa y el nuevo estado del entorno.
- Actualización:
El agente ajusta su política y/o sus funciones de valor basándose en la recompensa recibida y la nueva información del entorno.
- Iteración:
Repetir el proceso de interacción y actualización hasta que el agente optimice su política para maximizar la recompensa acumulada.

Tipos de Algoritmos de Aprendizaje por Reforzamiento

- Métodos de Valor:
 - El agente aprende a evaluar el valor de los estados o las acciones y toma decisiones basadas en esas evaluaciones.
 - Ejemplos:
 - Q-learning: Un algoritmo de aprendizaje fuera de política que busca aprender la función de valor de acción $Q(s, a)$. Actualiza los valores de Q utilizando la ecuación de Bellman.
 - SARSA (State-Action-Reward-State-Action): Un algoritmo de aprendizaje en política que actualiza la función de valor de acción basándose en la acción real tomada.
- Métodos de Política:
 - El agente aprende directamente una política que mapea estados a acciones, sin necesidad de aprender explícitamente las funciones de valor.
 - Ejemplos:
 - Gradient Policy Methods: Algoritmos que optimizan directamente la política utilizando gradientes, como el método REINFORCE.
- Métodos Actor-Critic:
 - Combina métodos de valor y métodos de política. El "actor" actualiza la política mientras que el "critic" evalúa las acciones utilizando una función de valor.
 - Ejemplos:
 - Actor-Critic: El actor ajusta la política basándose en la crítica proporcionada por el crítico, quien evalúa las acciones utilizando una función de valor de estado o de acción.

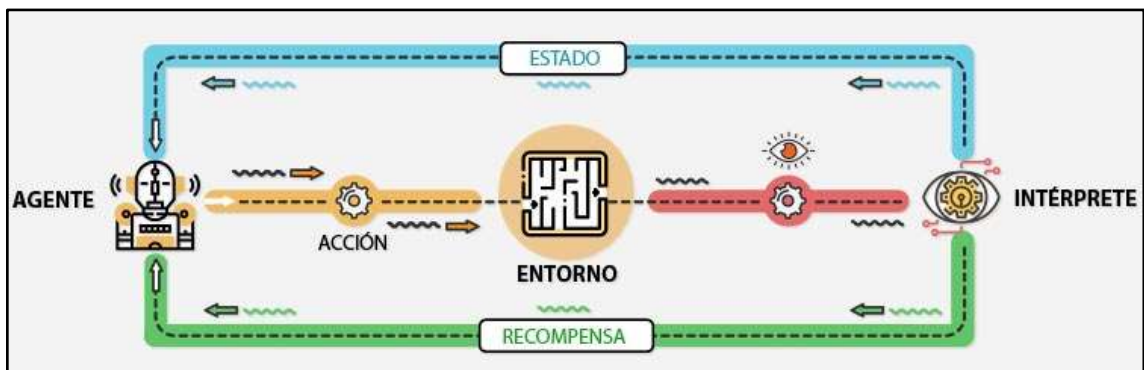


Figura N° 04: ¿Cómo funciona el aprendizaje por reforzamiento?

Aplicaciones del Aprendizaje por Reforzamiento.

- Robótica: Control de robots para tareas complejas como caminar, volar, y manipulación de objetos.
- Juegos: Entrenamiento de agentes para jugar juegos de estrategia y arcade, como AlphaGo de DeepMind.

- Sistemas de Recomendación: Personalización de recomendaciones basadas en la interacción del usuario con el sistema.
- Trading Algorítmico: Optimización de estrategias de trading en mercados financieros.
- Control de Procesos Industriales: Optimización de operaciones en plantas de producción y manufactura.

Ejemplo de Algoritmo: Q-learning

Q-learning es uno de los algoritmos más populares de aprendizaje por reforzamiento. El objetivo es aprender la función de valor de acción $Q(s, a)$, que proporciona una estimación de la recompensa esperada para tomar una acción a en un estado s .

Actualización de Q-learning:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a')] - Q(s, a)$$

donde:

- α es la tasa de aprendizaje.
- r es la recompensa recibida.
- γ es el factor de descuento.
- s' es el nuevo estado.
- $\max_{a'} Q(s', a')$ es el valor máximo esperado de la siguiente acción en el nuevo estado.

Desafíos del Aprendizaje por Reforzamiento

- Exploración vs. Explotación: Balancear entre explorar nuevas acciones y explotar acciones conocidas que proporcionan alta recompensa.
- Escalabilidad: Manejar grandes espacios de estados y acciones.
- Demora en la Recompensa: Las recompensas pueden no ser inmediatas, lo que complica la evaluación de acciones.
- Computación Intensiva: Los algoritmos pueden requerir mucho tiempo y recursos computacionales para entrenarse adecuadamente.

El aprendizaje por reforzamiento es una técnica poderosa para entrenar agentes autónomos a tomar decisiones en entornos complejos. A través de la interacción continua con el entorno y la optimización basada en la retroalimentación, los agentes pueden aprender políticas efectivas para maximizar la recompensa acumulada. Este enfoque ha demostrado ser eficaz en una amplia gama de aplicaciones, desde juegos hasta robótica y sistemas de recomendación, aunque también presenta desafíos significativos en términos de exploración, escalabilidad y computación.

➤ **Diferencias entre aprendizaje profundo y aprendizaje automático.**

El aprendizaje profundo (Deep Learning) y el aprendizaje automático (Machine Learning) son subcampos de la inteligencia artificial (IA) que, aunque relacionados, tienen diferencias significativas en sus enfoques, técnicas y aplicaciones. A continuación, se presentan las principales diferencias entre ambos:

Definiciones Básicas

- **Aprendizaje Automático (Machine Learning):**
Es un campo de la inteligencia artificial que permite a las máquinas aprender a partir de datos y realizar tareas específicas sin ser explícitamente programadas para cada una de ellas. Utiliza algoritmos que construyen modelos matemáticos basados en datos de entrenamiento.
- **Aprendizaje Profundo (Deep Learning):**
Es una subárea del aprendizaje automático que utiliza redes neuronales artificiales con muchas capas (profundas) para modelar patrones complejos en grandes volúmenes de datos. El aprendizaje profundo se inspira en la estructura y el funcionamiento del cerebro humano.

Diferencias Principales

- **Estructura de los Modelos:**
 - Machine Learning: Utiliza una variedad de algoritmos que incluyen árboles de decisión, máquinas de soporte vectorial (SVM), k-vecinos más cercanos (k-NN), regresión lineal y logística, entre otros. Estos modelos suelen ser menos complejos y tienen menos capas.
 - Deep Learning: Utiliza redes neuronales profundas con múltiples capas (capas ocultas). Los modelos de aprendizaje profundo incluyen redes neuronales convolucionales (CNN), redes neuronales recurrentes (RNN) y redes neuronales de retroalimentación (feedforward).
- **Requisitos de Datos:**
 - Machine Learning: Generalmente funciona bien con cantidades moderadas de datos. Los algoritmos de machine learning tradicionales pueden funcionar eficientemente con conjuntos de datos más pequeños y estructurados.
 - Deep Learning: Requiere grandes volúmenes de datos para entrenar modelos eficaces debido a la gran cantidad de parámetros que necesitan ajustarse. Es particularmente efectivo cuando se dispone de grandes conjuntos de datos no estructurados, como imágenes, texto y audio.

- Preprocesamiento de Datos:
 - Machine Learning: A menudo requiere un preprocesamiento significativo de datos y la selección manual de características (feature engineering) para mejorar el rendimiento del modelo.
 - Deep Learning: Puede automatizar gran parte del proceso de extracción de características. Las redes neuronales profundas pueden aprender representaciones de datos directamente a partir de datos brutos, lo que reduce la necesidad de ingeniería manual de características.
- Capacidad de Modelado:
 - Machine Learning: Es eficaz para problemas menos complejos y donde la relación entre las variables es relativamente simple y lineal.
 - Deep Learning: Puede modelar relaciones extremadamente complejas y no lineales, lo que lo hace ideal para tareas como el reconocimiento de voz, la visión por computadora y el procesamiento del lenguaje natural (NLP).
- Interpretabilidad:
 - Machine Learning: Los modelos suelen ser más interpretables y fáciles de entender. Por ejemplo, se puede visualizar un árbol de decisión o interpretar los coeficientes de una regresión lineal.
 - Deep Learning: Los modelos son a menudo considerados como "cajas negras" debido a su alta complejidad y la dificultad para interpretar cómo llegan a sus decisiones.
- Tiempo de Entrenamiento:
 - Machine Learning: Generalmente tiene tiempos de entrenamiento más cortos en comparación con los modelos de aprendizaje profundo.
 - Deep Learning: Requiere considerablemente más tiempo de entrenamiento debido a la complejidad de las redes y el gran número de parámetros.
- Infraestructura y Recursos Computacionales:
 - Machine Learning: Puede ejecutarse en hardware más estándar y no requiere necesariamente GPU (unidades de procesamiento gráfico) para entrenamiento.
 - Deep Learning: A menudo requiere hardware especializado como GPUs o TPUs (unidades de procesamiento tensorial) para manejar el entrenamiento intensivo en cálculo.

Ejemplos de Aplicaciones

- Machine Learning:
 - Detección de fraude en transacciones financieras.
 - Análisis de mercado y predicción de ventas.
 - Diagnóstico médico basado en análisis de datos estructurados.

Fundamentos Y Algoritmia Para Inteligencia Artificial

- Filtrado de spam en correos electrónicos.
- Deep Learning:
 - Reconocimiento facial y de objetos en imágenes.
 - Asistentes virtuales como Siri y Alexa.
 - Traducción automática de idiomas.
 - Generación de contenido como texto, imágenes y música.

Aunque el aprendizaje profundo es una subcategoría del aprendizaje automático, se distingue por su capacidad para manejar grandes volúmenes de datos y modelar relaciones muy complejas. El aprendizaje automático en general abarca una gama más amplia de técnicas y es adecuado para una variedad más amplia de problemas con diferentes niveles de complejidad y cantidad de datos disponibles. Ambos campos son fundamentales para el desarrollo de soluciones de inteligencia artificial, pero la elección entre uno y otro depende del problema específico, la disponibilidad de datos y los recursos computacionales.



Figura N° 05: Uso cotidiano de la IA.

TAREA N°02

Realiza operaciones con algebra lineal, vectores y matrices.

➤ Aritmética básica:

- **Propiedades de los números reales, como conmutativa, asociativa y distributiva.**

Los números reales son fundamentales en matemáticas y poseen varias propiedades que permiten realizar operaciones algebraicas de manera consistente y lógica. A continuación, se describen las propiedades más importantes: conmutativa, asociativa y distributiva, entre otras.

Propiedades de los Números Reales:

❖ Propiedad Conmutativa.

- Suma: El orden de los sumandos no afecta el resultado.

$$a + b = b + a$$

Ejemplo: $3 + 5 = 5 + 3$

- Multiplicación: El orden de los factores no afecta el resultado.

$$a \times b = b \times a$$

Ejemplo: $4 \times 6 = 6 \times 4$

❖ Propiedad Asociativa.

- Suma: La forma en que se agrupan los sumandos no afecta el resultado.

$$(a + b) + c = a + (b + c)$$

Ejemplo: $(2 + 3) + 4 = 2 + (3 + 4)$

- Multiplicación: La forma en que se agrupan los factores no afecta el resultado.

$$(a \times b) \times c = a \times (b \times c)$$

- Ejemplo: $(2 \times 3) \times 4 = 2 \times (3 \times 4)$

❖ Propiedad Distributiva:

- La multiplicación se distribuye sobre la suma.

$$a \times (b + c) = (a \times b) + (a \times c)$$

$$\text{Ejemplo: } 2 \times (3 + 4) = (2 \times 3) + (2 \times 4)$$

Otras Propiedades de los Números Reales

❖ Propiedad de Identidad.

- Suma: Existe un elemento neutro (0) tal que cualquier número sumado con 0 es el mismo número.

$$a + 0 = a$$

$$\text{Ejemplo: } 7 + 0 = 7$$

- Multiplicación: Existe un elemento neutro (1) tal que cualquier número multiplicado por 1 es el mismo número.

$$a \times 1 = a$$

$$\text{Ejemplo: } 9 \times 1 = 9$$

❖ Propiedad Inverso

- Suma: Para cada número real a , existe un número $-a$ tal que $a + (-a) = 0$.

$$a + (-a) = 0$$

$$\text{Ejemplo: } 5 + (-5) = 0$$

- Multiplicación: Para cada número real $a \neq 0$, existe un número $1/a$ tal que $a \times (1/a) = 1$.

$$a \times \frac{1}{a} = 1$$

$$\text{Ejemplo: } 4 \times \frac{1}{4} = 1$$

❖ Propiedad de Cierre.

- Suma: La suma de dos números reales es siempre un número real.

$a + b$ es un número real

Ejemplo: $5 + 7 = 12$

- Multiplicación: La multiplicación de dos números reales es siempre un número real.

$a \times b$ es un número real

Ejemplo: $3 \times 8 = 24$

Ejemplos Prácticos

- Conmutativa de la Suma:

$$7 + 3 = 3 + 7 \Rightarrow 10 = 10$$

- Asociativa de la Multiplicación:

$$(2 \times 5) \times 4 = 2 \times (5 \times 4) \Rightarrow 10 \times 4 = 2 \times 20 \Rightarrow 40 = 40$$

- Distributiva:

$$3 \times (4 + 5) = (3 \times 4) + (3 \times 5) \Rightarrow 9 = 12 + 15 \Rightarrow 27 = 27$$

- Identidad de la Multiplicación:

$$6 \times 1 = 6$$

- Inverso de la Suma:

$$8 + (-8) = 0$$

Estas propiedades son fundamentales en el álgebra y las matemáticas en general, y permiten la simplificación y manipulación de expresiones matemáticas de manera consistente.

➤ Álgebra elemental:

○ Resolución de ecuaciones lineales y cuadráticas.

- ❖ Una ecuación lineal es una ecuación de primer grado con respecto a una o más variables. La forma general de una ecuación lineal en una variable es:

$$ax + b = 0$$

donde a y b son constantes, y x es la variable.

❖ Pasos para Resolver Ecuaciones Lineales.

- ✓ Simplificar la Ecuación:
Si es necesario, simplifica ambos lados de la ecuación combinando términos semejantes.
- ✓ Mover los Términos:
Aísla la variable en un lado de la ecuación. Para hacer esto, puedes sumar, restar, multiplicar o dividir ambos lados de la ecuación por el mismo número (excepto cero).
- ✓ Resolver para la Variable:
Una vez que la variable esté aislada, resuelve la ecuación para encontrar su valor.

❖ Ejemplo de Ecuación Lineal

- ✓ Resolvamos la ecuación:

$$3x + 6 = 12$$

Restamos 6 de ambos lados para mover el término constante:

$$3x + 6 - 6 = 12 - 6$$

$$3x = 6$$

Dividimos ambos lados por 3 para aislar x :

$$\frac{3x}{3} = \frac{6}{3}$$

$$x = 2$$

❖ Resolución de Ecuaciones Cuadráticas.

Una ecuación cuadrática es una ecuación de segundo grado con respecto a una variable, y su forma general es:

$$ax^2 + bx + c = 0$$

donde a , b y c son constantes, y x es la variable. $a \neq 0$ para que la ecuación sea cuadrática.

❖ Métodos para Resolver Ecuaciones Cuadráticas

- Factorización.
- Completar el Cuadrado.
- Fórmula Cuadrática.
- Método Gráfico.

- Factorización

Si la ecuación cuadrática se puede factorizar, se puede escribir en la forma:

$$(mx + n)(px + q) = 0$$

Resolviendo para x :

$$mx + n = 0 \text{ y } px + q = 0$$

○ Ejemplo de Factorización

Resolvamos la ecuación:

$$x^2 - 5x + 6 = 0$$

Factorizamos:

$$(x - 2)(x - 3) = 0$$

Entonces, las soluciones son:

$$x - 2 = 0 \Rightarrow x = 2$$

$$x - 3 = 0 \Rightarrow x = 3$$

- Completar el Cuadrado

Este método implica reescribir la ecuación en la forma $((x - p)^2 = q)$ y luego resolver para (x) .

- Ejemplo de Completar el Cuadrado

Resolvamos la ecuación:

$$x^2 - 4x - 5 = 0$$

Movemos el término constante al otro lado:

$$x^2 - 4x = 5$$

- Completamos el cuadrado:

$$x^2 - 4x + 4 = 5 + 4$$

$$(x - 2)^2 = 9$$

Tomamos la raíz cuadrada de ambos lados:

$$x - 2 = \pm 3$$

Entonces, las soluciones son:

$$x - 2 = 3 \Rightarrow x = 5$$

$$x - 2 = -3 \Rightarrow x = -1$$

- Fórmula Cuadrática

La fórmula cuadrática es una fórmula general que proporciona las soluciones de cualquier ecuación cuadrática:

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

- Ejemplo de Fórmula Cuadrática

Resolvamos la ecuación:

$$2x^2 + 3x - 2 = 0$$

- Aplicamos la fórmula cuadrática:

$$a = 2, b = 3, c = -2$$

$$\begin{aligned}x &= \frac{-3 \pm \sqrt{3^2 - 4(2)(-2)}}{2(2)} \\x &= \frac{-3 \pm \sqrt{9+16}}{4} \\x &= \frac{-3 \pm \sqrt{25}}{4} \\x &= \frac{-3 \pm 5}{4}\end{aligned}$$

- Entonces, las soluciones son:

$$\begin{aligned}x &= \frac{-3+5}{4} = \frac{2}{4} = \frac{1}{2} \\x &= \frac{-3-5}{4} = \frac{-8}{4} = -2\end{aligned}$$

- Método Gráfico

Este método implica graficar la ecuación cuadrática y encontrar los puntos donde la curva intersecta el eje x . Las intersecciones representan las soluciones de la ecuación cuadrática.

- ❖ Ecuaciones Lineales: Resueltas mediante simplificación y aislamiento de la variable.
- ❖ Ecuaciones Cuadráticas: Resueltas mediante factorización, completar el cuadrado, la fórmula cuadrática o métodos gráficos.
- ❖ Ambos tipos de ecuaciones son fundamentales en álgebra y tienen amplias aplicaciones en matemáticas y ciencias aplicadas.

➤ Definición de vectores.

- **Operaciones vectoriales como suma, resta, multiplicación por un escalar y producto escalar.**

Las operaciones vectoriales son fundamentales en álgebra lineal y tienen numerosas aplicaciones en física, ingeniería, informática y otras disciplinas. A continuación, se detallan las principales operaciones vectoriales: suma, resta, multiplicación por un escalar y producto escalar.

Operaciones Vectoriales

❖ Suma de Vectores

La suma de dos vectores u y v se realiza sumando sus componentes correspondientes.

Si $u = (u_1, u_2, \dots, u_n)$ y $v = (v_1, v_2, \dots, v_n)$, entonces:

$$u + v = (u_1 + v_1, u_2 + v_2, \dots, u_n + v_n)$$

Ejemplo:

$$u = (1, 2, 3), v = (4, 5, 6)$$

$$u + v = (1 + 4, 2 + 5, 3 + 6) = (5, 7, 9)$$

❖ Resta de Vectores

La resta de dos vectores u y v se realiza restando sus componentes correspondientes.

Si $u = (u_1, u_2, \dots, u_n)$ y $v = (v_1, v_2, \dots, v_n)$, entonces:

$$u - v = (u_1 - v_1, u_2 - v_2, \dots, u_n - v_n)$$

Ejemplo:

$$u = (1, 2, 3), v = (4, 5, 6)$$

$$u - v = (1 - 4, 2 - 5, 3 - 6) = (-3, -3, -3)$$

❖ Multiplicación de un Vector por un Escalar.

La multiplicación de un vector u por un escalar k se realiza multiplicando cada componente del vector por el escalar.

Si $u = (u_1, u_2, \dots, u_n)$ entonces:

$$ku = (ku_1, ku_2, \dots, ku_n)$$

Ejemplo:

$$u = (1, 2, 3), k = 3$$

$$k u = 3 u = (3 \cdot 1, 3 \cdot 2, 3 \cdot 3) = (3, 6, 9)$$

❖ Producto Escalar (o Producto Punto).

El producto escalar de dos vectores u y v se calcula multiplicando sus componentes correspondientes y sumando los resultados.

Si $u = (u_1, u_2, \dots, u_n)$ y $v = (v_1, v_2, \dots, v_n)$, entonces:

$$u \cdot v = (u_1 \cdot v_1, u_2 \cdot v_2, \dots, u_n \cdot v_n)$$

Ejemplo:

$$u = (1, 2, 3), v = (4, 5, 6)$$

$$u \cdot v = 1 \cdot 4 + 2 \cdot 5 + 3 \cdot 6 = 4 + 10 + 18 = 32$$

Estas operaciones vectoriales son esenciales en diversas áreas de la ciencia y la ingeniería, proporcionando las bases para el análisis y la manipulación de vectores en el espacio.

➤ Matrices:

- Definición y representación de matrices.

Una matriz es un arreglo rectangular de números, símbolos o expresiones, dispuestos en filas y columnas. Los elementos de una matriz se organizan en una estructura bidimensional, lo que permite realizar diversas operaciones algebraicas y análisis.

Formalmente, una matriz A de tamaño $(m \times n)$ (m filas y n columnas) se denota como:

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

Donde:

- a_{ij} representa el elemento en la fila (i) y la columna (j) de la matriz.
- m es el número de filas.
- n es el número de columnas.

- Representación de Matrices

Las matrices se representan de diversas formas, dependiendo del contexto y del tamaño de la matriz.

- Matriz Rectangular**:

Una matriz con un número diferente de filas y columnas.

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

En este caso, A es una matriz de 2 x 3 (2 filas y 3 columnas).

- Matriz Cuadrada:

Una matriz con igual número de filas y columnas.

$$B = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

Aquí, B es una matriz de 3 x 3.

- Matriz Transpuesta:

La transpuesta de una matriz (A) , denotada (A^T) , se obtiene intercambiando las filas por columnas.

Si:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

Entonces:

$$A^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}$$

- Matriz Diagonal:

Una matriz cuadrada donde todos los elementos fuera de la diagonal principal son cero.

$$B = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 9 \end{bmatrix}$$

- Matriz Identidad:

Una matriz cuadrada donde todos los elementos de la diagonal principal son uno y todos los demás elementos son cero.

$$B = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- Matriz Nula (o Matriz Cero):
Una matriz en la que todos sus elementos son cero.

$$A = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

- **Operaciones matriciales como suma, resta, multiplicación y transposición.**
- Suma de Matrices

Dos matrices A y B de igual tamaño m x n se suman sumando sus elementos correspondientes:

$$C = A + B = \begin{pmatrix} a_{11} + b_{11} & a_{12} + b_{12} & \cdots & a_{1n} + b_{1n} \\ a_{21} + b_{21} & a_{22} + b_{22} & \cdots & a_{2n} + b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} + b_{m1} & a_{m2} + b_{m2} & \cdots & a_{mn} + b_{mn} \end{pmatrix}$$

- Multiplicación por un Escalar

Multiplicar una matriz (A) por un escalar (k) implica multiplicar cada elemento de (A) por (k) :

$$kA = \begin{pmatrix} k \cdot a_{11} & k \cdot a_{12} & \cdots & k \cdot a_{1n} \\ k \cdot a_{21} & k \cdot a_{22} & \cdots & k \cdot a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ k \cdot a_{m1} & k \cdot a_{m2} & \cdots & k \cdot a_{mn} \end{pmatrix}$$

- Producto de Matrices

El producto de dos matrices A de tamaño m x n y B de tamaño n x p da como resultado una matriz C de tamaño m x p, donde cada elemento c_{ij} se calcula como la suma de los productos de los elementos de la i-ésima fila de A por los elementos de la j-ésima columna de B:

$$C = AB$$

$$C_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$$

Ejemplo:

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad B = \begin{pmatrix} 2 & 0 \\ 1 & 3 \end{pmatrix}$$

$$C = AB = \begin{pmatrix} 1 \cdot 2 + 2 \cdot 1 & 1 \cdot 0 + 2 \cdot 3 \\ 3 \cdot 2 + 4 \cdot 1 & 3 \cdot 0 + 4 \cdot 3 \end{pmatrix} = \begin{pmatrix} 4 & 6 \\ 10 & 12 \end{pmatrix}$$

- Aplicaciones de las Matrices

- ✓ Las matrices son herramientas esenciales en muchas áreas, incluidas:
 - Sistemas de Ecuaciones Lineales: Resolver sistemas de ecuaciones lineales utilizando métodos como eliminación gaussiana o descomposición LU.
 - Transformaciones Lineales: Describir rotaciones, traslaciones y escalados en gráficos y geometría.
 - Gráficas y Redes: Representar grafos y redes en teoría de grafos y algoritmos.
 - Computación Científica: Modelar problemas físicos y simulaciones.
- ✓ Las matrices proporcionan un marco estructurado y poderoso para manejar datos y realizar operaciones complejas en matemáticas y ciencias aplicadas.

TAREA N°03

Estudia los principios y variables estadísticas.

➤ Estadística básica I.

La estadística es una disciplina matemática que permite recolectar, organizar y analizar datos según sea necesario. Esto puede incluir obtener resultados, comparar información y tomar decisiones más informadas, entre muchas otras aplicaciones.

Al emplear métodos, procedimientos y fórmulas, la estadística se considera la ciencia del análisis de datos. Su principal objetivo es ayudar a comprender lo que ocurre en el entorno a partir de la información disponible.

La estadística es útil para entender comportamientos, aspectos industriales y tendencias del mercado.

Un ejemplo de esto es Netflix, la plataforma de películas y series, que recopila datos de sus usuarios para identificar el contenido que prefieren. De esta manera, pueden decidir cuál será la película destacada o qué serie lanzarán el próximo mes.

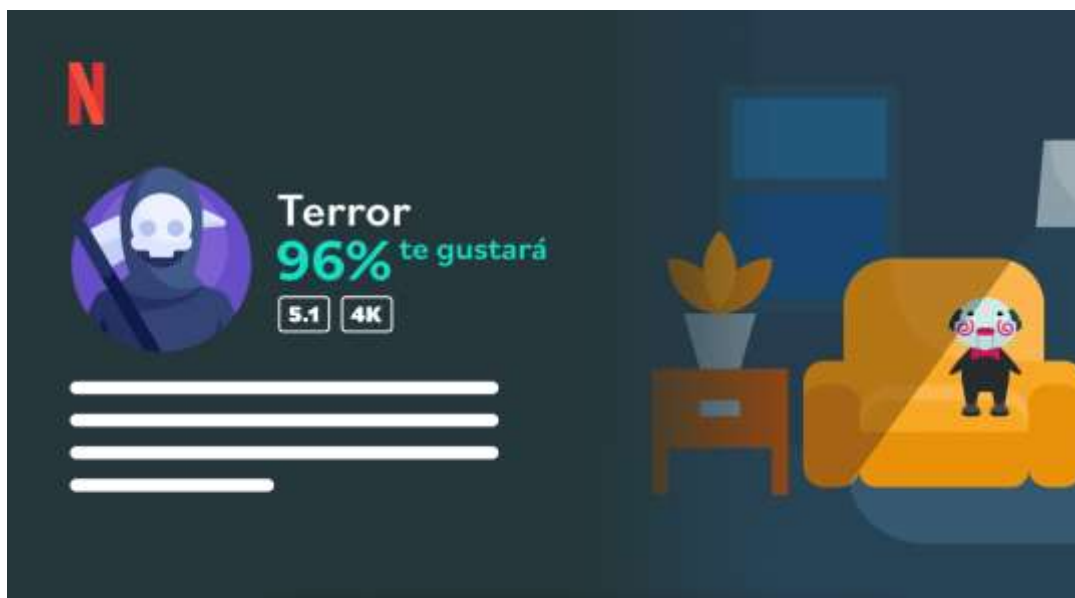


Figura N° 06: La estadística sirve para conocer comportamientos.

Google también analiza millones de búsquedas diarias para mejorar la experiencia de sus usuarios.



Figura N° 07: La estadística y las investigaciones médica.

Además, la estadística se utiliza en investigaciones médicas para evaluar la eficacia de medicamentos, en la economía para identificar los productos más consumidos y en la educación para determinar cuántas personas están estudiando en un país. En resumen, se aplica en diversos campos y situaciones donde es necesario interpretar grandes volúmenes de datos.

Ventajas de la Estadística.

- Permite resumir grandes cantidades de información, realizar comparaciones y predecir resultados.
- Es muy útil para tomar decisiones acertadas y responder preguntas sobre cualquier objeto de estudio.
- Apoya la justificación de ideas o afirmaciones con pocos argumentos.
- Es una herramienta valiosa para obtener conclusiones objetivas en investigaciones.

Tipos de Estadística

Existen dos tipos de estadística: descriptiva e inferencial.

- Estadística Descriptiva: Ayuda a organizar grandes cantidades de datos utilizando métodos, tablas y gráficos para presentar los resultados de manera ordenada. En este curso, te mostramos algunas de estas herramientas.
- Estadística Inferencial: Se enfoca en realizar conclusiones y deducciones a partir de una muestra de datos. Es útil para tomar decisiones o determinar tendencias en un grupo de información.

Por ejemplo, si deseas conocer el salario promedio de los pilotos en tu país, sería impráctico encuestar a todos. En cambio, puedes reunir respuestas de un grupo de pilotos y, basándote en los resultados, inferir la cifra promedio.

- **Media aritmética.**

La media aritmética, también conocida simplemente como promedio, es una medida de tendencia central que se utiliza para representar un conjunto de datos mediante un solo valor. Este valor se obtiene sumando todos los datos y dividiendo el resultado entre el número total de datos.

Fórmula

Para un conjunto de datos x_1, x_2, \dots, x_n , la media aritmética se calcula de la siguiente manera:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Donde:

- \bar{x} es la media aritmética.
- x_i representa cada uno de los valores del conjunto de datos.
- n es el número total de datos.

Ejemplo

Supongamos que tenemos los siguientes datos: 4, 8, 6, 5, 3, 7.

- Sumamos todos los valores:

$$4 + 8 + 6 + 5 + 3 + 7 = 33$$

- Dividimos la suma entre el número total de datos:

$$\bar{x} = \frac{33}{6} = 5.5$$

Por lo tanto, la media aritmética de estos datos es 5.5.

Propiedades de la Media Aritmética

- Simplicidad: La media aritmética es fácil de calcular y entender.
- Unicidad: Para un conjunto de datos dado, existe una única media aritmética.
- Afectada por valores extremos: La media aritmética puede ser influenciada significativamente por valores atípicos (extremos), lo que puede distorsionar la representación central del conjunto de datos.
- Aditividad: Si se combinan dos o más conjuntos de datos, la media aritmética del conjunto combinado puede calcularse a partir de las medias aritméticas individuales y los tamaños de los conjuntos.

Aplicaciones

La media aritmética se utiliza en una amplia variedad de campos, incluyendo:

- Economía: Para calcular el ingreso promedio de una población.
- Educación: Para determinar la nota promedio de los estudiantes.
- Ingeniería: Para encontrar valores promedio de mediciones repetidas.
- Ciencias Sociales: Para resumir datos sobre encuestas y estudios poblacionales.

Limitaciones

A pesar de sus ventajas, la media aritmética tiene algunas limitaciones:

- Sensibilidad a valores extremos: Como se mencionó, puede ser afectada por datos atípicos.
- No siempre representa bien los datos: En distribuciones muy asimétricas, la media puede no reflejar adecuadamente el centro de los datos.

En tales casos, otras medidas de tendencia central como la mediana o la moda pueden ser más representativas.

La media aritmética es una herramienta fundamental en estadística y análisis de datos, proporcionando una forma sencilla y efectiva de resumir conjuntos de datos numéricos.

○ **Mediana.**

La mediana es otra medida de tendencia central que representa el valor medio de un conjunto de datos ordenados. A diferencia de la media aritmética, la mediana no se ve afectada por valores extremos, lo que la hace útil en distribuciones asimétricas o cuando existen outliers.

Cálculo de la Mediana

El cálculo de la mediana depende del número de datos en el conjunto:

- Conjunto de datos con un número impar de elementos:
 - o Ordena los datos de menor a mayor.
 - o La mediana es el valor que se encuentra en el centro del conjunto ordenado.
- Conjunto de datos con un número par de elementos:
 - o Ordena los datos de menor a mayor.
 - o La mediana es el promedio de los dos valores centrales del conjunto ordenado.

Ejemplos

- Número impar de elementos:

Consideremos el conjunto de datos: 3, 1, 4, 7, 5.

- o Primero, ordenamos los datos: 1, 3, 4, 5, 7.
- o El valor central es el tercer elemento: 4.
- o Por lo tanto, la mediana es 4.

- Número par de elementos:

Consideremos el conjunto de datos: 8, 3, 5, 7, 6, 2.

- o Primero, ordenamos los datos: 2, 3, 5, 6, 7, 8.
- o Los valores centrales son el tercer y cuarto elementos: 5 y 6.
- o La mediana es el promedio de estos valores: $(5 + 6) / 2 = 5.5$.
- o Por lo tanto, la mediana es 5.5.

Propiedades de la Mediana

- Robustez: La mediana no se ve afectada por valores extremos o outliers.
- Simplicidad: Es fácil de calcular, especialmente para pequeños conjuntos de datos.
- Representatividad: En distribuciones sesgadas, la mediana puede ser una mejor representación del centro que la media aritmética.

Aplicaciones

La mediana se utiliza en diversas áreas:

- Economía: Para representar ingresos o precios cuando existen valores atípicos que distorsionan la media.
- Salud pública: Para analizar datos como el tiempo de espera en hospitales, donde pueden existir variaciones extremas.
- Educación: Para determinar la puntuación mediana en exámenes cuando hay una amplia variación en las calificaciones.

Limitaciones

Aunque la mediana es muy útil, tiene algunas limitaciones:

- Menos información sobre la distribución: La mediana no aprovecha toda la información de los datos y, por lo tanto, no proporciona una imagen completa de la distribución.
- Pérdida de sensibilidad: No refleja cambios en los datos de la misma manera que la media aritmética, especialmente en grandes conjuntos de datos.

La mediana es una medida crucial de tendencia central, especialmente adecuada en situaciones donde la media aritmética puede ser distorsionada por valores extremos. Su cálculo es sencillo y su robustez la hace una herramienta valiosa para resumir y representar conjuntos de datos, especialmente en distribuciones no simétricas o con outliers.

TAREA N°04

Estudia los principios y variables estadísticas.

➤ Estadística básica II.

○ Varianza.

La varianza es una medida de dispersión que indica cuánto varían los datos de un conjunto en relación a su media aritmética. Es esencial en estadística porque proporciona información sobre la variabilidad dentro de un conjunto de datos.

Fórmula de la Varianza,

Para un conjunto de datos x_1, x_2, \dots, x_n , la varianza se calcula de la siguiente manera:

❖ Varianza de una muestra (S^2):

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

❖ Varianza de una población (δ^2):

$$\delta^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

Donde:

- \bar{x} es la media de la muestra.
- μ es la media de la población.
- n es el número de datos en la muestra.
- N es el número de datos en la población.
- x_i representa cada uno de los valores del conjunto de datos.

Propiedades de la Varianza

- Siempre positiva: La varianza siempre es un número positivo o cero, ya que se basa en las diferencias al cuadrado.
- Sensible a valores extremos: La varianza considera todas las diferencias al cuadrado, por lo que los valores extremos tienen un mayor impacto.
- Adimensionalidad: La varianza se expresa en las unidades al cuadrado de los datos originales, lo que puede hacer que la interpretación sea menos intuitiva.

Aplicaciones

La varianza se utiliza en diversas áreas para analizar la variabilidad y dispersión de los datos:

- Finanzas: Para medir la volatilidad de los precios de activos.
- Calidad: Para evaluar la consistencia de procesos de manufactura.
- Ciencias Sociales: Para entender la dispersión en encuestas y estudios de comportamiento.

Limitaciones

- Sensibilidad a valores extremos: Valores muy altos o muy bajos influyen significativamente en la varianza, lo que puede distorsionar la percepción de la variabilidad.
- Complejidad: La varianza es menos intuitiva que otras medidas de dispersión como el rango o la desviación estándar, especialmente debido a que se expresa en unidades al cuadrado.

La varianza es una medida crucial de dispersión en estadística, que cuantifica la variabilidad de los datos en relación a su media. Proporciona una visión detallada de la dispersión de los datos, aunque su interpretación puede ser menos directa debido a que se expresa en unidades al cuadrado. A pesar de sus limitaciones, es fundamental para entender y analizar la distribución de los datos en numerosos campos de estudio.

○ Desviación estándar.

La desviación estándar es una medida de dispersión que indica cuánto se desvían, en promedio, los valores de un conjunto de datos respecto a su media. Es una medida muy útil porque se expresa en las mismas unidades que los datos originales, lo que facilita su interpretación.

Fórmula de la Desviación Estándar.

La desviación estándar se calcula como la raíz cuadrada de la varianza.

- Desviación estándar de una muestra (S):

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

- Desviación estándar de una población (δ):

$$\delta = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

Donde:

- \bar{x} es la media de la muestra.
- μ es la media de la población.
- n es el número de datos en la muestra.
- N es el número de datos en la población.
- x_i representa cada uno de los valores del conjunto de datos.

Propiedades de la Desviación Estándar.

- Unidades de medida: La desviación estándar se expresa en las mismas unidades que los datos originales, facilitando su interpretación.
- Sensibilidad a valores extremos: Al igual que la varianza, la desviación estándar es sensible a valores atípicos.
- Relación con la varianza: La desviación estándar es la raíz cuadrada de la varianza, lo que la convierte en una medida de dispersión más intuitiva.

Aplicaciones

La desviación estándar se utiliza en numerosas áreas para evaluar la dispersión y variabilidad de los datos:

- Finanzas: Para medir la volatilidad de los precios de activos y el riesgo asociado a las inversiones.
- Control de calidad: Para monitorear y controlar la variabilidad en procesos de manufactura.
- Ciencias sociales: Para analizar la variabilidad en encuestas y estudios de comportamiento humano.
- Educación: Para evaluar la dispersión de calificaciones de los estudiantes y entender la variabilidad en el rendimiento académico.

Limitaciones

- Sensibilidad a valores extremos: Valores muy altos o muy bajos pueden influir significativamente en la desviación estándar, distorsionando la percepción de la variabilidad.
- No siempre apropiada: En distribuciones muy sesgadas o con datos categóricos, la desviación estándar puede no ser la medida más adecuada de dispersión.

La desviación estándar es una medida fundamental de dispersión que cuantifica la variabilidad de los datos en relación a su media. Se expresa en las mismas unidades que los datos originales, lo que facilita su interpretación. A pesar de su sensibilidad a valores extremos, es ampliamente utilizada en diversos campos para analizar y entender la dispersión y la variabilidad de los datos.

○ Probabilidades.

La **probabilidad** es una rama de la matemática que estudia la posibilidad de que ocurran eventos. Es una medida cuantitativa que varía entre 0 y 1, donde 0 indica que un evento es imposible y 1 indica que un evento es seguro. Las probabilidades permiten predecir la ocurrencia de eventos en condiciones de incertidumbre.

Conceptos Básicos de Probabilidad.

- Experimento Aleatorio: Un proceso que produce un resultado incierto. Ejemplos incluyen lanzar una moneda, tirar un dado, o seleccionar una carta de una baraja.
- Espacio Muestral (S): El conjunto de todos los posibles resultados de un experimento aleatorio. Por ejemplo, al lanzar un dado, el espacio muestral es {1, 2, 3, 4, 5, 6}.
- Evento (E): Un subconjunto del espacio muestral. Por ejemplo, al lanzar un dado, el evento "sacar un número par" es {2, 4, 6}.
- Probabilidad de un Evento (P(E)): Una medida que indica la posibilidad de que ocurra un evento, calculada como:

$$P(E) = \frac{\text{Número de resultados favorables}}{\text{Número de resultados posibles}}$$

Tipos de Probabilidad.

- Probabilidad Clásica: Utilizada cuando todos los resultados en el espacio muestral son igualmente probables. Ejemplo: La probabilidad de sacar un 3 en un dado justo es $\frac{1}{6}$.
- Probabilidad Empírica (Frecuentista): Basada en la observación o experimentación. Se calcula como la frecuencia relativa de la ocurrencia de un evento. Ejemplo: Si lanzamos una moneda 100 veces y sale cara 55 veces, la probabilidad empírica de obtener cara es $\frac{55}{100} = 0.55$.

- Probabilidad Subjetiva: Basada en la intuición, juicio o experiencia personal. Ejemplo: La probabilidad de que llueva mañana puede ser estimada por una persona según su experiencia y conocimiento.

Reglas de Probabilidad.

- Regla de la Suma: La probabilidad de la ocurrencia de al menos uno de dos eventos mutuamente excluyentes es la suma de sus probabilidades individuales.

$$P(A \cup B) = P(A) + P(B)$$

- Regla del Complemento: La probabilidad de que un evento no ocurra es 1 menos la probabilidad de que ocurra.

$$P(A^c) = 1 - P(A)$$

- Regla de la Multiplicación para Eventos Independientes: La probabilidad de que dos eventos independientes ocurran juntos es el producto de sus probabilidades individuales.

$$P(A \cap B) = P(A) \cdot P(B)$$

Ejemplos

- Lanzar un Dado:
Espacio Muestral: {1, 2, 3, 4, 5, 6}
Probabilidad de obtener un 4: $\frac{1}{6}$
- Lanzar Dos Monedas:
Espacio Muestral: {HH, HT, TH, TT}
Probabilidad de obtener al menos una cara: $\frac{3}{4}$
- Selección de Cartas:
Espacio Muestral (baraja estándar de 52 cartas)
Probabilidad de sacar un As: $\frac{4}{52} = \frac{1}{13}$

Aplicaciones de la Probabilidad

- Juegos de Azar: Determinar las probabilidades en juegos como loterías, ruletas y cartas.
- Seguros: Calcular el riesgo y las primas de seguros.
- Negocios: Tomar decisiones basadas en la evaluación de riesgos y probabilidades.
- Ciencia: Realizar experimentos y análisis estadísticos para hacer inferencias sobre poblaciones.

La probabilidad es una herramienta matemática fundamental que nos permite cuantificar la incertidumbre y hacer predicciones sobre la ocurrencia de eventos. A través de sus diferentes enfoques y reglas, la probabilidad encuentra aplicaciones en numerosas áreas, desde los juegos de azar hasta la toma de decisiones en negocios y la realización de investigaciones científicas.

➤ Hipótesis estadística.

○ P-valor.

El valor p (p-valor) es una medida utilizada en pruebas de hipótesis estadísticas para determinar la significancia de los resultados obtenidos en un estudio. Es la probabilidad de obtener un resultado igual o más extremo que el observado, bajo la hipótesis nula de que no hay efecto o diferencia real en la población.

Características del valor p:

- Rango de Valores: El valor p varía entre 0 y 1. Un valor p cercano a 0 indica que los datos observados son muy improbables bajo la hipótesis nula, lo que sugiere evidencia en contra de esta hipótesis. Un valor p cercano a 1 indica que los datos observados son muy probables bajo la hipótesis nula, lo que sugiere que no hay suficiente evidencia para rechazarla.
- Interpretación: Si el valor p es menor que un umbral predefinido (generalmente 0.05 o 0.01), se considera que los resultados son estadísticamente significativos y se rechaza la hipótesis nula en favor de la alternativa. Por el contrario, si el valor p es mayor que el umbral, no se puede rechazar la hipótesis nula y los resultados no se consideran estadísticamente significativos.
- Decisión Estadística: La decisión de rechazar o no la hipótesis nula se basa en comparar el valor p con el nivel de significancia (alfa) elegido. Si el valor p es menor que alfa, se rechaza la hipótesis nula; de lo contrario, no se rechaza.

- Nivel de Significancia (Alfa): Es el nivel de probabilidad aceptado como criterio para rechazar la hipótesis nula. Es elegido por el investigador antes de realizar la prueba y generalmente se establece en 0.05 o 0.01.

Cálculo del valor p:

El cálculo del valor p depende del tipo de prueba estadística realizada y la distribución de los datos. En general, se sigue el siguiente procedimiento:

- Se plantea una hipótesis nula (H_0) y una hipótesis alternativa (H_1).
- Se realiza la prueba estadística correspondiente (t-test, chi-cuadrado, ANOVA, etc.).
- Se calcula el valor p, que es la probabilidad de obtener los resultados observados o más extremos si la hipótesis nula fuera cierta.
- Se compara el valor p con el nivel de significancia (alfa) predefinido.
- Se toma una decisión estadística: si el valor p es menor que alfa, se rechaza la hipótesis nula; de lo contrario, no se rechaza.

Aplicaciones del valor p:

- En medicina, para evaluar la eficacia de tratamientos.
- En ciencias sociales, para analizar encuestas y estudios de comportamiento.
- En investigación, para validar resultados experimentales.
- En negocios, para evaluar la efectividad de estrategias de marketing.

El valor p es una medida fundamental en pruebas de hipótesis estadísticas que indica la probabilidad de obtener los resultados observados bajo la hipótesis nula. Su interpretación permite tomar decisiones sobre la significancia de los resultados obtenidos en un estudio, lo que lo convierte en una herramienta clave en el análisis de datos y la investigación científica.

REFERENCIAS BIBLIOGRÁFICAS

1. AWS. (s.f.). *¿Cuál es la diferencia entre el aprendizaje supervisado y el no supervisado?* <https://aws.amazon.com/es/compare/the-difference-between-machine-learning-supervised-and-unsupervised/>
2. AWS. (s.f.). *¿Qué es la inteligencia artificial (IA)?* <https://aws.amazon.com/es/what-is/artificial-intelligence/>
3. Concepto. (s.f.). *Probabilidad y estadística.* <https://concepto.de/probabilidad-y-estadistica/>
4. Digixem360. (14 de junio de 2023). *¿Qué es el aprendizaje por refuerzo?* <https://www.itmastersmag.com/inteligencia-artificial/que-es-el-aprendizaje-por-refuerzo/>
5. Espinosa, S. (09 de marzo de 2022). *Qué es una matriz y ejemplos.* <https://www.unprofesor.com/matematicas/que-es-una-matriz-y-ejemplos-749.html>
6. GCF Global. (s.f.). *Estadística básica - ¿Qué es la estadística?* . <https://edu.gcfglobal.org/es/estadistica-basica/que-es-la-estadistica/1/>
7. Insight. (01 de junio de 2023). *Inteligencia Artificial.* <https://www.tomorrow.bio/es/post/qu%C3%A9-es-el-aprendizaje-por-refuerzo-2023-06-4569932077-ai>
8. Instituto de Ingeniería de Conocimiento. (s.f.). *Aprendizaje profundo por refuerzo.* <https://www.iic.uam.es/aprendizaje-profundo-por-refuerzo/>
9. Parlamento Europeo. (08 de setiembre de 2020). *¿Qué es la inteligencia artificial y cómo se usa?* <https://www.europarl.europa.eu/topics/es/article/20200827STO85804/que-es-la-inteligencia-artificial-y-como-se-usa>
10. Rodó, P. (1 de octubre de 2020). *Vector.* <https://economipedia.com/definiciones/vector.html>
11. Smartick. (26 de febrero de 2024). *La probabilidad: qué es y cómo la utilizamos en el día a día.* <https://www.smartick.es/blog/matematicas/probabilidad-y-estadistica/probabilidad-que-es/>
12. Soporte Minitab. (s.f.). *¿Qué es la varianza?* <https://support.minitab.com/es-mx/minitab/help-and-how-to/statistics/basic-statistics/supporting-topics/data-concepts/what-is-the-variance/>
13. Superprof. (s.f.). *Todo sobre la mediana.* <https://www.superprof.es/apuntes/escolar/matematicas/estadistica/descriptiva/mediana.html>

REFERENCIAS DE IMÁGENES

Figura N° 01: IA en la automatización de procesos industriales.

https://d1.awsstatic.com/diagrams/product-page-diagrams/Diagram_ai-category_machine-learning-workflow.89d4ebdfb4159dfc70b4eff6027eca4ca59ccaec.png

Figura N° 02: Principales tecnológicas de la IA.

<https://d2908q01vomqb2.cloudfront.net/f1f836cb4ea6efb2a0b1b99f41ad8b103eff4b59/2018/05/04/ImagesSageMaker2-2.png>

Figura N° 03: Diferencias entre el ML supervisado y el no supervisado.

<https://docs.aws.amazon.com/images/sagemaker/latest/dg/images/ml-concepts-10.png>

Figura N° 04: ¿Cómo funciona el aprendizaje por reforzamiento?

<https://www.iic.uam.es/wp-content/uploads/2018/12/aprendizaje-refuerzo.jpg>

Figura N° 05: Uso cotidiano de la IA.

<https://www.europarl.europa.eu/resources/library/images/20201019PHT89615/20201019PHT89615-cl.jpg>

Figura N° 06: La estadística sirve para conocer comportamientos.

https://media.gcflearnfree.org/content/61d5c09ec4da77185ca9f222_01_05_2022/Para-que%CC%81-sirve-la-estadi%CC%81stica.png

Figura N° 07: La estadística y las investigaciones médica.

https://media.gcflearnfree.org/content/61d5c09ec4da77185ca9f222_01_05_2022/Usos-de-la-estadi%CC%81stica.png



RECURSO DIDÁCTICO PARA EL APRENDIZAJE